

המכללה האקדמית להנדסה אפקה

תואר שני במערכות תבוניות

מספר סטודנט: 123456789

לזיהוי משטרי שוק ולחיזוי כיוון יומי

ניתוח רב-נכסי ויציבות משטרים

והשוואה למודלי בסיס ול- χ^2 סטטיסטיקה

עבודת גמר בקורס שיטות מתקדמות בלמידת מכונה

מתן אשל

מספר סטודנט: 123456789

אוגוסט 2023

תוכן העניינים

מבוא ושאלות המחקר	1
נתונים ופרוטוקול ניסוי	2
פאנל הנכסים	3
יעד החיזוי והחלוקה הכרונולוגית	4
שחזור ומעקב אחר	5
מתודולוגיה	6
בחירת מספר המצבים	7
לעומת	8
ומשך משטר	9
ניסויים ומדדי הערכה	10
פשוטים	11
מדדים	12
ניסויי	13
תוצאות מבנה המשטרים	14
בחירת מודל ויציבות	15
פירוש בי-טסט	16
סביב מעברים	17
מול	18
תוצאות חיזוי יום־קדימה	19
תמונה כללית	20
תוצאות לפי נכס	21
שגיאת דוגמת	22
למה לבדו עלול להטעות	23
לעומת	24
על	25
דיון	26
למה חיזוי יום־קדימה נשאר קשה	27
מה ה-כך מוסיף	28
מול	29
ניתן לקרוא ל-כך	30
משך המשטר והנחת	31
הרחבה עתידית	32
ניסוח כ-כך	33
למה לשלב בתוך	34
אלגוריתמים אפשריים	35
מה מראה הספרות	36
כיצד היינו מבצעים את הניסוי בצורה הוגנת	37
מגבלות	38
מסקנות	39
א' שחזור והרצה	40

יותר ימי מסחר קלנדריים אך היסטוריה קצרה יותר בתחילת המדגם כל מחשוב מתוך התצפיות הזמינות בפועל לכל נכס

ההורדה בוצעה עם ☐ לחישובי התשואה והיעד נעשה שימוש ב-☐ כקשר העמודה זמינה וב-☐ כ-☐ אין השלמה מלאכותית של ימים חסרים שורות ☐ חסרות או ערכים לא־סופיים מוסרים ולאחר בניית ☐ מוסרות גם שורות שאין עבורן היסטוריית ☐ מספקת או ☐ של יום הבא בניתוח -☐-☐ נעשה שימוש רק בתאריכים החופפים בפועל בין הסדרות

☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐ ☐

לכל יום t נבנה וקטור תצפיות בן ארבעה רכיבים

$$\mathbf{x}_t = \left[r_t, \sigma_t^{(20)}, R_t, \Delta \log V_t \right], \quad \square \square \square$$

כאשר

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right) \quad \square\square\square$$

היא התשואה הלוגריתמית $\sigma_t^{(20)}$ היא סטיית התקן המתגלגלת של תשואות R_t הימים האחרונים. הוא מייצגת את תרומתם

כל n מתגלגל מחושב מהעבר וההווה בלבד. אין שימוש בנתוני יום $t + 1$ בבניית n של יום t .

יעד החיזוי והחלוקה הכרונולוגית

יַעַד הַחִיזוּי הוּא סִימָן הַתְּשׁוּאָה בְּיוֹם הַבָּא □

$$y_t = \mathbb{1}[r_{t+1} \geq 0]. \quad \square \square \square$$

החלוקה היא כרונולוגית בקירוב ו**שם** ש**מייצגת את המידע הכלכלי והחברתי של כל אחת מהקבוצות**.
כדי למנוע בלבול בשורה אחרונה בכל הנתונים מוסרת אם היסטוריה שלה שיך כבר
להיסטוריה הבאה.

[illegible]

בריצת היסטוריון ההגדרו קבועים מראש ולכן לא בוצע
על שלושת היסטוריון ובפרט היסטוריון של
הותאמו על בלבד ונבדקו על אותו כרונולוגיים נשמרו
כמפורשים כי היסטוריון מתחילים אין היסטוריון אינו משמש לבחירה או התאמה

$$\gamma_t(k) = P(S_t = k \mid X_{1:t}),$$

ולא $\gamma_t(k)$ שמוחלק בעזרת כל רצף ה- $\gamma_t(k)$ העתידיים בפועל נשמר גם $\gamma_t(k)$ מוגבל של היסטוריית $X_{t+1}, X_{t+2}, \dots$ כדי לאתחל את הרצפים אך אין שימוש ב- $X_{t+1}, X_{t+2}, \dots$ בעת חיזוי יום $t + 1$

בגרסת $\gamma_t(k)$ תחזית התשואה של היום הבא היא ממוצע משוקלל לפי $\gamma_t(k)$ במקום להסתמך רק על $\gamma_t(k)$ המוטיבציה היא שיום שנמצא בדיוק בגבול בין שני $\gamma_t(k)$ לא צריך להיחשב כאילו המודל בטוח לחלוטין ב- $\gamma_t(k)$ אחד $\gamma_t(k)$ אי-הוודאות מסוכמת באמצעות $\gamma_t(k)$ מנורמלת

$$H_t = - \frac{\sum_{k=1}^K \gamma_t(k) \log \gamma_t(k)}{\log K}.$$

H_t קרוב לאפס כאשר $\gamma_t(k)$ מרוכז כולו ב- $\gamma_t(k)$ אחד וגדל כאשר כמה $\gamma_t(k)$ מקבלים הסתברויות דומות

משך משטר

ב- $\gamma_t(k)$ מסדר ראשון משך השהייה ב- $\gamma_t(k)$ הוא גאומטרי הממוצע המשתמע מ- $\gamma_t(k)$ - $\gamma_t(k)$ הוא

$$E[D_i] = \frac{1}{1 - a_{ii}}.$$

בדוח משווים את הערך הזה ל- $\gamma_t(k)$ $\gamma_t(k)$ $\gamma_t(k)$ השוואה זו אינה בודקת את כל התפלגות ה- $\gamma_t(k)$ ולכן $\gamma_t(k)$ $\gamma_t(k)$ נשאר הרחבה אפשרית כאשר רוצים למדל $\gamma_t(k)$ במפורש

ניסויים ודדי הערכה

פשוטים

ה- $\gamma_t(k)$ הושווה תחילה לארבעה כללים פשוטים כדי לוודא שכל יתרון אינו נובע רק ממגמת שוק בסיסית $\gamma_t(k)$ $\gamma_t(k)$ - $\gamma_t(k)$ זהו השם שנשמר ב- $\gamma_t(k)$ בהערכת ה- $\gamma_t(k)$ הסופית התחזית הקבועה מבוססת למעשה על ממוצע $\gamma_t(k)$ בכל היסטוריית ה- $\gamma_t(k)$ הזמינה כלומר $\gamma_t(k)$ לאחר סיום $\gamma_t(k)$

$\gamma_t(k)$ $\gamma_t(k)$ מנבא שהכיוון הבא יהיה זהה לכיוון האחרון שנצפה

$\gamma_t(k)$ $\gamma_t(k)$ כלל סיבתי המבוסס על ממוצע נע קצר של תשואות זמינות עד היום הנוכחי $\gamma_t(k)$ $\gamma_t(k)$ מודל מעבר נצפה בין $\gamma_t(k)$ ללא $\gamma_t(k)$ הפרמטרים נאמדים מהיסטוריית ה- $\gamma_t(k)$ - $\gamma_t(k)$ בלבד

שלושת ה- $\gamma_t(k)$ הפשוטים שדורשים אומדן היסטורי משתמשים כמו ה- $\gamma_t(k)$ הסופי במידע שהיה זמין לפני תחילת ה- $\gamma_t(k)$ אף אחד מהם אינו משתמש ב- $\gamma_t(k)$ לצורך התאמה

בדיקות אלה אינן נועדו לשפר את ׀׀׀׀ בדיעבד ׀ אלא לבדוק אם המסקנות התיאוריות נשארות סבירות גם מעבר לריצה יחידה ׀

תוצאות מבנה המשטרים

בחירת מודל ויציבות

[illegible]


ב- 0000000000 השוואת המועמדים מראה מדוע $K = 4$ נבחר הטבלה משתמשת ב- 0000 בעל 000000000000
 00000000000000000000 הטוב ביותר לכל K לפני ה- 00000 הסופי על 00000000000000000000

000 000000000 000	000 0000000	0000 00 0 0000	0000	K
00000	00000000	000000-	000	0
0000	00000000	000000-	000	0
0000	00000000	000000-	000	0

טבלה 00 השוואת $K = 2, 3, 4$ עבור 000 בשלב בחירת המודל 000000000000 000000000000 גבוה יותר 000 פחות שלילי עדיף 000 נמוך יותר עדיף

[illegible]

עבור $K=4$ ה- K הממוצע בין חמשת ה- K היה $K=4$ עם מינימום של 0.000000 גם 0.000000 ו- 0.000000 היו יציבים מאוד עם 0.000000 של כ- 0.000000 ו- 0.000000 בהתאמה לעומת זאת 0.000000 - 0.000000 ו- 0.000000 היו פחות יציבים ב- $K=4$ עם 0.000000 של כ- 0.000000 ו- 0.000000 לכן המסקנה אינה שכל נכס 0.000000 מארבעה משטרים 0.000000 אלא שהמודל העשיר יציב במיוחד בחלק מהנכסים ופחות באחרים

[illegible]

פירוט מודל


המודל מיועד להערכת מחירי המניות של החברה, תוך התבססות על נתונים היסטוריים. המודל אינו מבטיח תוצאות מדויקות, והוא אינו מהווה ייעוץ פיננסי.

מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר
מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר
מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר
מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר
מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר	מחיר

טבלה זו מפרטת את המודל, הכולל את המידע הנדרש להערכת מחירי המניות של החברה.

המודל מבצע ניתוח של נתונים היסטוריים, תוך התבססות על מודל מתמטי. המודל אינו מבטיח תוצאות מדויקות, והוא אינו מהווה ייעוץ פיננסי.

המודל מבצע ניתוח של נתונים היסטוריים, תוך התבססות על מודל מתמטי. המודל אינו מבטיח תוצאות מדויקות, והוא אינו מהווה ייעוץ פיננסי.




אזור זה מפרט את המודל, הכולל את המידע הנדרש להערכת מחירי המניות של החברה.

סביבת המודל

המודל מבצע ניתוח של נתונים היסטוריים, תוך התבססות על מודל מתמטי. המודל אינו מבטיח תוצאות מדויקות, והוא אינו מהווה ייעוץ פיננסי.

המודל מבצע ניתוח של נתונים היסטוריים, תוך התבססות על מודל מתמטי. המודל אינו מבטיח תוצאות מדויקות, והוא אינו מהווה ייעוץ פיננסי.


המחקר מציג תוצאות של מודל HMM המנסה להבחין בין מצבי שוק שונים. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.



איור 1: מודל HMM של SPY. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.

תוצאות מודל HMM

המודל לא שילם ולא השתתף באימונים, לכן הוא משמש בדיקת SPY-המודל. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.



איור 2: מודל HMM של SPY. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.


המודל הנדיר לא הופיע בחפיפה זו ולכן אי אפשר להשתמש בו כדי לאמת אותו בתקופת ה-SPY. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.

סקירה כללית של המחקר

כדי לבדוק האם המודל של SPY משקף מצב שוק רחב יותר, חושבו סטטיסטיקות של נכסים אחרים מותנות ב-SPY. המודל מתבסס על נתונים היסטוריים של SPY, ומנסה לזהות מצבים שונים בהתבססות על נתונים אלו.

[illegible][illegible]

1



איור 1: השוואת תוצאות דיוקן הכוונה למחרת (DPA) עבור מודלי היסודיים והמודל ה-HMM. השוואת הדיוקן הכוונה למחרת (DPA) עבור מודלי היסודיים והמודל ה-HMM. השוואת הדיוקן הכוונה למחרת (DPA) עבור מודלי היסודיים והמודל ה-HMM.

תוצאות לפי נכס

יש כמה מקרים מקומיים מעניינים. ב-HMM, הדיוקן הכוונה למחרת (DPA) הוא גבוה יותר מאשר במודלי היסודיים. הדיוקן הכוונה למחרת (DPA) הוא גבוה יותר מאשר במודלי היסודיים. הדיוקן הכוונה למחרת (DPA) הוא גבוה יותר מאשר במודלי היסודיים.

הפיזור הזה חשוב יותר מהדירוג הממוצע. אינו נכשל בכל נכס אך גם אינו מנצח בצורה יציבה. אותו דבר נכון למודלי היסודיים ול-HMM. הקלאסיים לכן אין סימנים לכך שה-HMM עדיף.

שיטת ההשוואה דוגמת

בדרך כלל, רק את סימן התחזית ולכן עבור המודלים שמחזירים תחזית מספרית לתשואה נבדקו גם הסימנים על ה-HMM. על ה-HMM, על מחיר הסגירה המשתמע. הטבלה הבאה מציגה את המכרה הייחוס המרכזי.

מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי
מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי
מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי
מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי
מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי
מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי	מכרה הייחוס המרכזי

טבלה 1: מדדי חזיון מספריים על ההבדלים בין מודלי היסודיים והמודל ה-HMM. קטנים מאוד על מחיר מוצג כמדד משלים בלבד.

גם במדדי היסודיים אין כאן יתרון מעשי גדול. כמעט זהים ל-HMM. הדבר מחזק את המסקנה שהערך המרכזי של ה-HMM בניסוי הנוכחי אינו תחזית נקודתית מדויקת יותר.

למה לבדוק עלול להטעות

במסגרת המחקר למשלם המודל המצוטט ו-1000 מגיעים של כ-1000000 עם זאת המודל המצוטט מגיע ל-1000 של כ-1000000 אך המודל המצוטט מגיע ל-1000 של כ-1000000 ו-1000 של כ-1000000 משיג 1000 של כ-1000000 כלומר חלק ניכר מה-1000000 נובע מחוסר איזון בין ימי 1000 ו-1000 ולא מיכולת חזקה לדרג ימים לפי הסתברות לעלייה

זו הסיבה שבדוח לא מתייחסים ל-1000 מעל 1000 כהוכחה אוטומטית ל-1000000 מודל שמנבא את המחלקה הנפוצה יכול לקבל 1000000 סביר גם בלי להבין את דינמיקת היום הבא


לעומת המודל המצוטט

בממוצע המודל המצוטט משיג לעומת המודל המצוטט הפער קטן אך הוא עקבי עם האינטואיציה שלפיה שימוש בכל וקטור ה-1000000 שומר מידע שנורק ב-1000000 לדוגמה ב-1000 הגיע ל-1000 בעוד המודל המצוטט הגיע ל-1000 ב-1000 הפער גדול יותר המודל לעומת המודל מנגד קיימים גם נכסים שבהם המודל אינו משפר

לכן המסקנה אינה ש-1000 המודל המצוטט את המודל המצוטט אלא שהוא דרך הגיונית יותר לנצל המודל המצוטט מאשר המודל המצוטט כאשר משתמשים ב-1000 לתחזית

המודל המצוטט על

שלושת המודלים המצוטט מציגים תמונה מעורבת המודל המצוטט השיג בהתאמה המודל המצוטט ו-1000 המודל המצוטט השיג המודל המצוטט הממוצע הוא המודל המצוטט לעומת המודל המצוטט אינו מנצח בכל המודל והפער הכולל קטן



איור 10: בשלושה המודלים המצוטט על המודל המצוטט אינו מפגין יתרון עקבי בין התקופות

בדיקת המודל המצוטט מחזקת את הצורך בניסוח זהיר ייתכן שמידע על מסיע בתקופות מסוימות אך לא נמצא המודל המצוטט יציב שניתן להכליל לכל תקופה

דיון

הממצא המרכזי של העבודה אינו מנבא את השוק המצוטט אלא כמעט ההפך גם המודל המצוטט פשוטים וגם המודל המצוטט מתקשים להפיק עקבי לחיזוי היום הבא מתוך ארבעת המודלים שנבדקו התוצאה השלילית הזו אינה כישלון של הניסוי היא מאפשרת להפריד בין שתי יכולות שונות של מודל המודל המצוטט ו-1000000

1. למה חיזוי יום-קדימה נשאר קשה?

חיזוי סימן התשואה ליום הבא הוא בעיה בעלת יחס 10^{-10} – 10^{-12} נמוך. כמו כן, חיזוי סימן התשואה ליום בודד, העובדה שגם חיזוי סימן התשואה ליום בודד אינו ייחודי לסימן התשואה ליום בודד, אינם מייצרים יתרון עקבי תומכת בפרשנות שהקושי אינו ייחודי לסימן התשואה ליום בודד.

בנוסף, רגישות סימן התשואה לסימן התשואה ליום הבא, בתקופות שבהן שיעור ימי העלייה גבוה, פשוט שמנבא את הכיוון הדומיננטי יכול להשיג מסל מעל לכן, חיזוי סימן התשואה ליום בודד אינו ייחודי לסימן התשואה ליום בודד, ברוב הנכסים מדדים אלה נשארו קרובים לסימן התשואה ליום בודד, ולכן לא נכון להסיק מה- 10^{-10} בלבד שיש יכולת סימן התשואה ליום בודד.

2. מה הסיכוי כן מוסיף?

בניגוד לסימן התשואה ליום הבא, בונה ייצוג מפורש של מצב לטנטי ושל דינמיקת המעבר בין סימן התשואה ליום הבא, ההפרדה בין סימן התשואה ליום הבא במספר ממדים בויזמנית, סימן התשואה ליום הבא, והאנטרופיה עולה כאשר המודל נמצא באזור סימן התשואה ליום הבא, חשוב לא להפריז בפרשנות של הקשר הזה. מאחר שסימן התשואה ליום הבא נגזר מאותו סימן התשואה ליום הבא, גבוה סביב סימן התשואה ליום הבא, היא בחלקה תוצאה צפויה של הגדרת הגבול, לכן זהו סימן התשואה ליום הבא של סימן התשואה ליום הבא לא עוצמאי.

הראיות החיצוניות יותר מגיעות ממקומות אחרים, שלא שימש באימון מפריד בין חלק מה- 10^{-10} והקורלציה של 10^{-10} עם נכסים אחרים משתנה לפי סימן התשואה ליום הבא, גם כאן מדובר ב- 10^{-10} – 10^{-12} סימן התשואה ליום הבא, ולא בהוכחה סיבתית. אך הוא מראה שה- 10^{-10} קשור למאפייני שוק שאינם חלק ישיר מה- 10^{-10} סימן התשואה ליום הבא של סימן התשואה ליום הבא.

לכן הסימן מספק סימן התשואה ליום הבא במקום לשאול רק מהאם מחר יהיה סימן התשואה ליום הבא ניתן לשאול בבאזיה סוג סביבה סטטיסטית אנחנו נמצאים כמה המודל בטוח בכך וכיצד נכסים אחרים נוטים להתנהג בסביבה זו? יכולת שאינה נמדדת ישירות בסימן התשואה ליום הבא.

3. סימן התשואה ליום הבא מול סימן התשואה ליום הבא

העבודה מראה גם 10^{-10} – 10^{-12} בין מספר סימן התשואה ליום הבא לבין יציבות $K = 2$ נוטה להיות יציב מאוד בין סימן התשואה ליום הבא, אך גם יחסית $K = 4$ מאפשר להפריד עשירים יותר ובי- 10^{-10} סימן התשואה ליום הבא, הוא גם יציב מאוד לעומת זאת ב- 10^{-10} – 10^{-12} וב- 10^{-10} הוא רגיש יותר לאתחולל מכאן שאין הצדקה לקבוע מספר סימן התשואה ליום הבא אוניברסלי לכל סימן התשואה ליום הבא.

4. האם ניתן לקרוא לסימן התשואה ליום הבא וסימן התשואה ליום הבא?

לא באופן אוטומטי. מספר סימן התשואה ליום הבא הוא סימן התשואה ליום הבא, והמודל אינו לומד מושגים כלכליים בשפה אנושית. לכן בדוח נעשה שימוש בשמות תיאוריים רק כאשר הנתונים תומכים בהם. למשל סימן התשואה ליום הבא מכונה 10^{-10} – 10^{-12} משום שהוא נדיר בעל סימן התשואה ליום הבא, גבוה וסימן התשואה ליום הבא עמוק. גם שם זה הוא פרשנות ולא סימן התשואה ליום הבא.

5. משך המשטר והנחת

ההשוואה בין $1/(1 - a_{ii})$ לבין סימן התשואה ליום הבא אמפירי לא חשפה פער גדול בממוצע עבור סימן התשואה ליום הבא, לטעון שהנחת הגאומטרית נכשלת בניסוי זה. עם זאת, בדיקת ממוצעים אינה בוחנת סימן התשואה ליום הבא או סימן התשואה ליום הבא של סימן התשואה ליום הבא, יכול להיות הרחבה טובה אם רוצים למדל משך משטר במפורש.

בסיכום, התמונה העקבית ביותר היא שה- 10^{-10} סימן התשואה ליום הבא מתאים בפרויקט זה יותר לסימן התשואה ליום הבא, מאשר לסימן התשואה ליום הבא. זו אינה נסיגה מהמטרה המקורית אלא ממצא אמפירי שמגדיר בצורה מדויקת יותר היכן המודל מספק ערך.

הרחבה עתידית

הרחבה טבעית של הפרויקט היא מעבר מבעיה של חיזוי לבעיה של קבלת החלטות סדרתית ב- $P(y_{t+1} = 1 \mid x_t)$ מנסים ללמוד פונקציה מה- $P(y_{t+1} = 1 \mid x_t)$ אל יעד ידוע מראש למשל $P(y_{t+1} = 1 \mid x_t)$ הסוכן אינו נדרש רק לומר מה צפוי לקרות הוא בוחר פעולה המשפיעה על הרווח המצטבר לאורך זמן

ניסוח כ- $P(y_{t+1} = 1 \mid x_t)$

ניתן להגדיר את בעיית המסחר כ- $P(y_{t+1} = 1 \mid x_t)$ שבו בכל יום קיימים $P(y_{t+1} = 1 \mid x_t)$ ו- $P(y_{t+1} = 1 \mid x_t)$ לדוגמה

אם $P(y_{t+1} = 1 \mid x_t)$ ארבעת ה- $P(y_{t+1} = 1 \mid x_t)$ הנוכחיים $P(y_{t+1} = 1 \mid x_t)$ של ה- $P(y_{t+1} = 1 \mid x_t)$ והפוזיציה הנוכחית בתיק

אם $P(y_{t+1} = 1 \mid x_t)$ בגרסה פשוטה $P(y_{t+1} = 1 \mid x_t)$ $P(y_{t+1} = 1 \mid x_t)$ בגרסה רציפה יותר $P(y_{t+1} = 1 \mid x_t)$ $P(y_{t+1} = 1 \mid x_t)$ בנקס

אם $P(y_{t+1} = 1 \mid x_t)$ תשואת התיק נטו לאחר $P(y_{t+1} = 1 \mid x_t)$ עם $P(y_{t+1} = 1 \mid x_t)$ אופציונלי ל- $P(y_{t+1} = 1 \mid x_t)$ או לסיכון

ניסוח אפשרי של $P(y_{t+1} = 1 \mid x_t)$ הוא

$$R_{t+1} = w_t r_{t+1} - c|w_t - w_{t-1}| - \lambda \text{RiskPenalty}_{t+1},$$

כאשר c מייצג עלות עסקה ו- λ את משקל רתיעת הסיכון בניגוד לניסוי החיזוי הנוכחי כאן $P(y_{t+1} = 1 \mid x_t)$ אינם פרט שוליים שמחליפה פוזיציה לעיתים קרובות יכולה להיראות מוצלחת לפני עלויות ולהיכשל לאחריהן

למה לשלב $P(y_{t+1} = 1 \mid x_t)$ בתוך $P(y_{t+1} = 1 \mid x_t)$

הרעיון המעניין ביותר אינו להחליף את ה- $P(y_{t+1} = 1 \mid x_t)$ ב- $P(y_{t+1} = 1 \mid x_t)$ אלא להשתמש ב- $P(y_{t+1} = 1 \mid x_t)$ כשכבת $P(y_{t+1} = 1 \mid x_t)$ במקום לתת לסוכן $P(y_{t+1} = 1 \mid x_t)$ כמו $P(y_{t+1} = 1 \mid x_t)$ ניתן להזין את כל הווקטור

$$[\gamma_t(1), \dots, \gamma_t(K), H_t],$$

כך שהסוכן יודע גם מהו $P(y_{t+1} = 1 \mid x_t)$ הסביר וגם כמה ה- $P(y_{t+1} = 1 \mid x_t)$ בטוח בום לדוגמה $P(y_{t+1} = 1 \mid x_t)$ יכולה ללמוד באופן עצמאי שתקופה בעלת $P(y_{t+1} = 1 \mid x_t)$ חד דורשת פעולה שונה מתקופה שבה שני $P(y_{t+1} = 1 \mid x_t)$ מתחרים ביניהם אין צורך לקודד מראש כלל כמו ב- $P(y_{t+1} = 1 \mid x_t)$ מוכרים ה- $P(y_{t+1} = 1 \mid x_t)$ בודק אם מידע זה אכן מועיל ל- $P(y_{t+1} = 1 \mid x_t)$

הניסוי הנקי ביותר יהיה $P(y_{t+1} = 1 \mid x_t)$ בשלוש רמות

אם $P(y_{t+1} = 1 \mid x_t)$ הסוכן רואה רק את ארבעת ה- $P(y_{t+1} = 1 \mid x_t)$ המקוריים

אם $P(y_{t+1} = 1 \mid x_t)$ אותם $P(y_{t+1} = 1 \mid x_t)$ בתוספת $P(y_{t+1} = 1 \mid x_t)$

אם $P(y_{t+1} = 1 \mid x_t)$ תוספת $P(y_{t+1} = 1 \mid x_t)$ ומידע על הפוזיציה הנוכחית

השוואה כזו הייתה עונה על שאלה ממוקדת האם מידע לטנטי על $P(y_{t+1} = 1 \mid x_t)$ מוסיף ערך אינקרמנטלי למדיניות מעבר למידע הגולמי שכבר קיים ב- $P(y_{t+1} = 1 \mid x_t)$ זהו המשך ישיר יותר של העבודה מאשר להריץ אלגוריתם שאינו משתמש בתוצאות ה- $P(y_{t+1} = 1 \mid x_t)$

11

א' שחזור והרצה

להרצה מחדש

כל ריצה חדשה נכתבת לתיקייה 000000000000 חדשה ואינה אמורה לדרוס את התוצרים שעליהם מבוסס הדוח. הדבר חשוב במיוחד משום שמקור הנתונים חיצוני ונתוני 000000 000000 יכולים להתעדכן לאורך זמן.

מקורות

- [1] Hirotugu Akaike. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716–723, 1974.
- [2] Ran Aroussi. yfinance: Download market data from yahoo! finance's api. Python software and documentation, 2024.
- [3] Leonard E. Baum, Ted Petrie, George Soules, and Norman Weiss. A maximization technique occurring in the statistical analysis of probabilistic functions of markov chains. *The Annals of Mathematical Statistics*, 41(1):164–171, 1970.
- [4] Jan Bulla and Ingo Bulla. Stylized facts of financial time series and hidden semi-markov models. *Computational Statistics & Data Analysis*, 51(4):2192–2209, 2006.
- [5] Luigi Catello, Ludovica Ruggiero, Lucia Schiavone, and Mario Valentino. Hidden markov models for stock market prediction. *arXiv preprint arXiv:2310.03775*, 2023.
- [6] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, pages 1861–1870, 2018.
- [7] James D. Hamilton. A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2):357–384, 1989.
- [8] hmmlearn developers. hmmlearn: Hidden markov models in python. Software documentation, 2024.
- [9] Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006.
- [10] Garvin Kruthof and Sebastian Müller. Can deep reinforcement learning beat 1/n? *Finance Research Letters*, 75:106866, 2025.
- [11] Xiao-Yang Liu, Hongyang Yang, Jiechao Gao, and Christina Dan Wang. Finrl: Deep reinforcement learning framework to automate trading in quantitative finance. *arXiv preprint arXiv:2111.09395*, 2021.
- [12] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. MIT Press, Cambridge, MA, 2012.
- [13] Jennifer Pohle, Roland Langrock, Floris M. van Beest, and Niels M. Schmidt. Selecting the number of states in hidden markov models: Pragmatic solutions illustrated using animal movement. *Journal of Agricultural, Biological and Environmental Statistics*, 22:270–293, 2017.
- [14] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.
- [15] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [16] Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464, 1978.
- [17] Hongyang Yang, Xiao-Yang Liu, Shan Zhong, and Anwar Walid. Deep reinforcement learning for automated stock trading: An ensemble strategy. In *Proceedings of the First ACM International Conference on AI in Finance (ICAIF '20)*, pages 1–8, 2020.
- [18] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep reinforcement learning for trading. *arXiv preprint arXiv:1911.10107*, 2019.