

המכללה האקדמית להנדסה אפקה

תואר שני במערכות תבניות

Gaussian HMM

לזיהוי משטרי שוק ולחיזוי כיוון יומי

ניתוח רב-נכסי ויציבות משטרים

והשוואה למודלי בסיס ול-Supervised ML

עבודת גמר בקורס שיטות מתקדמות בלמידת מכונה

מתן אשל

מספר סטודנט: 203502802

אוגוסט 2026

תקציר

עבודה זו בוחנת את השימוש ב-Gaussian Hidden Markov Model (HMM) בשתי רמות: חיזוי כיוון התשואה ביום הבא, וזיהוי משטרי שוק סמויים בעלי משמעות סטטיסטית. הניסוי הסופי כולל תשעה נכסים מייצגים — SPY, QQQ, IWM, TLT, GLD, HYG, BTC-USD, JPM ו-NVDA — עבור חלון בקשה 2014-01-01--2024-12-31. לכל יום מחושבים ארבעה Features: תשואה לוגריתמית, תנודתיות מתגלגלת ל-20 ימים, טווח תוך-יומי ושינוי לוגריתמי בנפח. החלוקה כרונולוגית ומוגנת מזליגה: Validation Train, Test. בשלב בחירת ה-HMM preprocessing מותאם על Train בלבד; לאחר נעילת K וה- seed המודל וה- scaler מותאמים מחדש על כל המידע שלפני ה-Test (Train+Validation). מודלי ה-ML Supervised הקבועים מאומנים על Train בלבד.

לכל נכס נבדקו $K \in \{2, 3, 4\}$ וחמישה seeds. בחירת K ו- seed נעשתה לפי log-likelihood Validation. בלבד. בנוסף ל-assignment state hard נבדקה תחזית המבוססת על כל וקטור ה-posterior. המודל הושווה לארבעה Baselines פשוטים ולשלושה מודלי Forest Random Regression, Logistic ML: Supervised ו-HistGradientBoosting.

מבחינת חיזוי, לא נמצא יתרון עקבי ל-HMM. ממוצע ה-DPA בין תשעת הנכסים היה 54.54% ל-Naive. train-mean, Regression, Logistic 54.14%, Chain, Markov Discrete 53.90%, Random 53.27%, Forest, HMM 53.06%, soft-posterior, HMM 52.49%, HistGradientBoosting ו-HMM 52.06% ל-hard-state; persistence Naive ו-Average Moving 5 היו קרובים ל-50%. לעומת זאת, ברמת ייצוג מבנה השוק התקבלו ממצאים תיאוריים ברורים יותר. ב-SPY, מודל $K = 4$ יצר states בעלי תשואה, drawdown, volatility, range ומשך שהייה שונים מאוד; ה-entropy posterior עלה סביב מעברי state; מבנה המצבים היה יציב מאוד בין seeds; ומדרד, VIX שלא שימש באימון, הפריד בין חלק מהמשטרים. בנוסף נמצא כי הקורלציות בין SPY לנכסים אחרים משתנות כתלות במשטר.

המסקנה המרכזית היא כי בפרויקט זה ה-HMM שימושי יותר כ-**estimator market-state latent** מאשר כמודל forecasting point ליום הבא. אין בעבודה טענה לרווחיות מסחר, למובהקות סטטיסטית של ההבדלים התיאוריים או ליתרון כללי של HMM על פני מודלים אחרים.

מילות מפתח: Hidden Markov Model, משטרי שוק, posterior uncertainty, walk-forward, directional prediction, Reinforcement Learning, Supervised Learning.

תוכן העניינים

1	מבוא ושאלות המחקר	1
1	נתונים, Features ופרוטוקול ניסוי	2
1	פאנל הנכסים	2.1
2	Vector Feature	2.2
2	יעד החיזוי והחלוקה הכרונולוגית	2.3
2	שחזור ומעקב אחר provenance	2.4
3	מתודולוגיה	3
3	Model Markov Hidden	3.1
3	בחירת מספר המצבים	3.2
3	state Hard לעומת posterior Soft	3.3
4	Persistence ומשך משטר	3.4
4	ניסויים, Baselines ומדדי הערכה	4
4	Baselines פשוטים	4.1
4	Baselines ML Supervised	4.2
5	מדדים	4.3
5	ניסויי Robustness	4.4
5	תוצאות: מבנה המשטרים	5
5	בחירת מודל ויציבות	5.1
6	פירוש states ב-SPY	5.2
7	uncertainty Posterior סביב מעברים	5.3
8	validation External מול VIX	5.4
8	behavior Cross-asset	5.5
9	תוצאות: חיזוי יום-קדימה	6
9	תמונה כללית	6.1
9	תוצאות לפי נכס	6.2
10	שגיאת magnitude: דוגמת SPY	6.3
10	למה DPA לבדו עלול להטעות	6.4
10	state Hard לעומת posterior Soft	6.5
10	robustness Walk-forward על SPY	6.6
11	דיון	7
11	למה חיזוי יום-קדימה נשאר קשה?	7.1
11	מה ה-HMM כן מוסיף?	7.2
12	Expressiveness מול robustness	7.3
12	האם ניתן לקרוא ל-"Bull", "Bear" ו-"Crash"?	7.4
12	משך המשטר והנחת Markov	7.5
12	הרחבה עתידית: Learning Reinforcement Regime-aware	8
12	ניסוח כ-Process Decision Markov	8.1
13	למה לשלב HMM בתוך RL?	8.2
13	אלגוריתמים אפשריים	8.3
13	מה מראה הספרות?	8.4
13	כיצד היינו מבצעים את הניסוי בצורה הוגנת?	8.5

14	9 מגבלות
14	10 מסקנות
15	א' שחזור והרצה

1 מבוא ושאלות המחקר

סדרות זמן פיננסיות אינן מתנהגות בהכרח כשהליך יחיד ויציב. תקופות שקטות מתחלפות בתקופות תנודתיות, התפלגות התשואות משתנה, והקשר בין נכסים יכול להתחזק או להיחלש. מודלים מסוג switching regime מתארים מצב זה באמצעות משתנה חבוי שמייצג את הסביבה הסטטיסטית שבה השוק נמצא [7]. מודל מרקוב חבוי נותן לכך מסגרת הסתברותית פשוטה: state סמוי מתפתח לפי שרשרת מרקוב, והתצפיות נוצרות מהתפלגות שתלויה ב-state [12, 14].

הפרויקט התחיל משאלה יחסית ישירה: האם Gaussian HMM הלומד מצבי שוק סמויים יכול לשפר חיזוי של כיוון התשואה ביום הבא, וכיצד מספר המצבים K משפיע על התוצאה. רעיון דומה מופיע בעבודות המיישמות HMM לנתוני מניות לצורך forecasting [5]. עם זאת, לאחר הריצה הראשונית התברר שהשאלה החיזונית לבדה צרה מדי: גם אם DPA אינו גבוה, ייתכן שהמודל עדיין מזהה מבנה סטטיסטי חשוב שאינו נגיש ל-classifier רגיל.

לכן בגרסה הסופית הוגדרו שלוש שאלות מחקר:

1. **Forecasting:** האם HMM משפר חיזוי direction next-day ביחס ל-Baselines פשוטים ולמודלי Supervised ML המקבלים את אותם Features?

2. **Representation:** האם ה-States Hidden נבדלים באופן עקבי ב-volume range, daily volatility, return, occupancy drawdown, behavior, ו-persistence?

3. **information: Regime:** האם identity state וה-uncertainty posterior מספקים מידע נוסף על מעברי משטר, VIX ומבנה הקורלציה בין נכסים?

ההבחנה בין forecasting לבין representation היא מרכזית. מודל יכול להיות חלש בחיזוי נקודתי ועדיין להיות שימושי כאומד של מצב חבוי. לכן העבודה אינה מחפשת רק "מודל מנצח", אלא בודקת איזה סוג מידע כל משפחת מודלים מספקת ומה ניתן להסיק ממנו באופן זהיר.

2 נתונים, Features ופרוטוקול ניסוי

2.1 פאנל הנכסים

במקום להוסיף מספר גדול של מניות דומות, נבחר פאנל קטן יחסית אך מגוון מבחינה כלכלית. הנתונים נמשכו דרך yfinance [2] עבור חלון בקשה של 2014-01-01--2024-12-31. הנכסים הם:

- SPY — שוק המניות האמריקאי הרחב, ומשמש גם נכס ייחוס לניתוח cross-asset.
- QQQ — מניות צמיחה וטכנולוגיה גדולות.
- IWM — מניות small-cap.
- TLT — אג"ח ממשלתיות אמריקאיות ארוכות.
- GLD — זהב.
- HYG — אג"ח חברות high-yield, כנכס אשראי מסוכן יחסית.
- BTC-USD — נכס אלטרנטיבי בעל volatility גבוהה.
- JPM — מניה גדולה מסקטור הפיננסים.
- NVDA — מניית צמיחה/high-beta.

המטרה בבחירה זו אינה לבצע picking stock אלא לבדוק אם אותה מתודולוגיה מתנהגת באופן דומה על asset classes בעלי מאפייני סיכון שונים. חשוב לציין שהטווח לעיל הוא חלון הבקשה המשותף; בפועל זמינות הנתונים שונה מעט בין הנכסים. בפרט, סדרת BTC-USD מתחילה מאוחר יותר ולכן מכילה יותר ימי מסחר קלנדריים אך היסטוריה קצרה יותר בתחילת המדגם. כל split מחושב מתוך התצפיות הזמינות בפועל לכל נכס.

ההורדה בוצעה עם `auto_adjust=False`. לחישובי התשואה והיעד נעשה שימוש ב-`Adj Close` כאשר העמודה זמינה, וב-`Close` כ-`fallback`. אין השלמה מלאכותית של ימים חסרים: שורות OHLCV חסרות או ערכים לא-סופיים מוסרים, ולאחר בניית Features מוסרות גם שורות שאין עבורן היסטוריית `rolling` מספקת או `target` של יום הבא. בניתוח `cross-asset` נעשה שימוש רק בתאריכים החופפים בפועל בין הסדרות.

2.2 Vector Feature

לכל יום t נבנה וקטור תצפיות בן ארבעה רכיבים:

$$\mathbf{x}_t = \left[r_t, \sigma_t^{(20)}, R_t, \Delta \log V_t \right], \quad (1)$$

כאשר

$$r_t = \log \left(\frac{P_t}{P_{t-1}} \right) \quad (2)$$

היא התשואה הלוגריתמית, $\sigma_t^{(20)}$ היא סטיית התקן המתגלגלת של תשואות 20 הימים האחרונים, R_t הוא `range daily` המבוסס על `High` ו-`Low`, ו- $\Delta \log V_t$ הוא שינוי לוגריתמי בנפח. הבחירה בתכונות פשוטות נעשתה במכוון: הן מייצגות כיוון, תנודתיות, טווח מסחר ופעילות, בלי להעמיס אינדיקטורים טכניים שקשה לבודד את תרומתם. כל statistic מתגלגל מחושב מהעבר וההווה בלבד. אין שימוש בנתוני יום $t + 1$ בבניית Features של יום t .

2.3 יעד החיזוי והחלוקה הכרונולוגית

יעד החיזוי הוא סימן התשואה ביום הבא:

$$y_t = \mathbb{I}[r_{t+1} \geq 0]. \quad (3)$$

החלוקה היא כרונולוגית בקירוב 70% Train, 15% Validation ו-15% Test. אין `shuffle` כדי למנוע `leakage` בגבולות, שורה אחרונה בכל `partition` מוסרת אם ה-`target` שלה שייך כבר ל-`partition` הבא.

חשוב להבחין בין שלב בחירת המודל לבין ההתאמה הסופית לפני `Test`. בזמן השוואת מועמדי HMM ה-`scaler` מותאם על Train בלבד, המועמדים מאומנים על Train ונמדדים על Validation. רק לאחר ש- K וה-`seed` ננעלים, ה-HMM הנבחר וה-`scaler` מותאמים מחדש על כל היסטוריית `pre-Test`, כלומר, על Train+Validation ואז Test נשאר מחוץ לאימון ולתאמת ה-`preprocessing`. זהו סטנדרטי לאחר `selection model` ואינו חושף את המודל ל-`Test`.

בריצת ה-`ML Supervised` הוגדרו `hyperparameters` קבועים מראש ולכן לא בוצע `selection model` על Validation. שלושת ה-`classifiers`, ובפרט ה-`scaler` של `Logistic Regression`, הותאמו על Train בלבד ונבדקו על אותו Test כרונולוגי. נשמרו `assertions` מפורשים כי `split target-safe` מתקיים, אין `shuffle` ו-`Test` אינו משמש לבחירה או התאמה. לכן ההשוואה משתמשת באותו `Vector Feature` ובאותו `Test`, אך היקף היסטוריית האימון אינו זהה לחלוטין בין ה-HMM הסופי לבין מודלי ה-`Supervised`; הנקודה הזו נלקחת בחשבון בפרשנות התוצאות.

2.4 שחזור ומעקב אחר provenance

כל ריצה נשמרת בתיקייה חדשה עם `manifest` המכיל תאריך, `Git`, `commit`, גרסאות `packages`, רשימת נכסים, `seeds`, `hyperparameters` וסטמס השלמה. הריצה המרכזית של ה-HMM היא `extended_20260811_121957`, והריצה של מודלי ה-`ML Supervised` היא `supervised_20260811_133344`. תוצאות קודמות נשמרו לצורך `audit` אך אינן משמשות למענות המספריות בדוח זה.

3 מתודולוגיה

3.1 Model Markov Hidden

נסמן ב- $S_t \in \{1, \dots, K\}$ את ה-State Hidden בזמן t . הנחת Markov מסדר ראשון היא:

$$P(S_t | S_1, \dots, S_{t-1}) = P(S_t | S_{t-1}). \quad (4)$$

מטריצת המעבר A מכילה את ההסתברויות

$$a_{ij} = P(S_t = j | S_{t-1} = i), \quad (5)$$

ולכן האלכסון שלה מתאר persistence: ערך גבוה של a_{ii} פירושו שהמודל מצפה להישאר באותו state.

ב-Gaussian HMM התצפית המולטיווריאטית תלויה ב-state דרך Gaussian emission:

$$\mathbf{X}_t | S_t = k \sim \mathcal{N}(\boldsymbol{\mu}_k, \Sigma_k). \quad (6)$$

בפרויקט נעשה שימוש ב-hmmlearn [8] עם covariance מסוג full. פרמטרי המודל נלמדים באמצעות Baum-Welch EM / [3]. האלגוריתם מבצע לסירוגין חישוב posterior על רצף המצבים ועדכון של ההסתברויות המעבר ופרמטרי הפליטה, עד convergence.

3.2 בחירת מספר המצבים

לכל נכס נבדקו $K = 2, 3, 4$ וחמישה seeds: 42, 123, 456, 789, 2026. הבחירה של K ו-seed נעשתה לפי log-likelihood Validation בלבד. AIC ו-BIC נשמרו כאבחוני complexity נוספים [1, 16], אך לא שימש בשום שלב של selection. model

בחירת מספר states ב-HMM אינה בעיה טריוויאלית: מודל עשיר יותר יכול לשפר likelihood אך גם ליצור states נדירים או רגישים לאתחול [13]. לכן בנוסף לציון ההתאמה נבדקו occupancy ויציבות בין seeds.

3.3 state Hard לעונות Soft posterior

ב-decoding hard כל יום מקבל state יחיד. לצורך ההערכה מחוץ למדגם השתמשנו ב-inference past-only: עבור יום Test בזמן t , רצף הקלט נחתך כך שאינו כולל תצפיות אחרי t . לכן וקטור ההסתברויות שבו משתמשת התחזית הוא

$$\gamma_t(k) = P(S_t = k | X_{1:t}), \quad (7)$$

ולא posterior שמוחלק בעזרת כל רצף ה-Test העתיד. בפועל נשמר גם context מוגבל של היסטוריית Train/Validation כדי לאתחל את inference הרצפי, אך אין שימוש ב- $X_{t+1}, X_{t+2}, \dots$ בעת חיזוי יום $t + 1$. בגרסת soft, forecast תחזית התשואה של היום הבא היא ממוצע משוקלל לפי γ_t , במקום להסתמך רק על argmax. המוטיבציה היא שיום שנמצא בדיוק בגבול בין שני regimes לא צריך להיחשב כאילו המודל בטוח לחלוטין ב-state אחד.

אי-הוודאות מסוכמת באמצעות entropy מנורמלת:

$$H_t = -\frac{\sum_{k=1}^K \gamma_t(k) \log \gamma_t(k)}{\log K}. \quad (8)$$

H_t קרוב לאפס כאשר posterior מרוכז כולו ב-state אחד, וגדל כאשר כמה states מקבלים הסתברויות דומות.

3.4 Persistence ומשך משטר

ב-HMM מסדר ראשון משך ההייה ב-state הוא גאומטרי. הממוצע המשתמע מ-probability self-transition הוא:

$$E[D_i] = \frac{1}{1 - a_{ii}}. \quad (9)$$

בדוח משווים את הערך הזה ל-duration. mean empirical decoded זהו אינה בודקת את כל התפלגות ה-duration, ולכן Model Semi-Markov Hidden נשאר הרחבה אפשרית כאשר רוצים למדל duration במפורש [4].

4 ניסויים, Baselines ומדדי הערכה

4.1 Baselines פשוטים

ה-HMM הושווה תחילה לארבעה כללים פשוטים, כדי לוודא שכל יתרון אינו נובע רק ממגמת שוק בסיסית:

- **mean: train - Naive** זהו השם שנשמר ב-artifact. בהערכת ה-Test הסופית התחזית הקבועה מבוססת למעשה על ממוצע next_log_return בכל היסטוריית ה-pre-Test הזמינה, כלומר, Train+Validation, לאחר סיום selection. model

- **persistence: Naive** מנבא שהכיוון הבא יהיה זהה לכיוון האחרון שנצפה.

- **5: Average Moving** כלל סיבתי המבוסס על ממוצע נע קצר של תשואות זמינות עד היום הנוכחי.

- **Chain: Markov Discrete** מודל מעבר נצפה בין Up/Down ללא Hidden States; הפרמטרים נאמדים מהיסטוריית ה-pre-Test בלבד.

שלושת ה-Baselines הפשוטים שדורשים אומדן היסטורי משתמשים, כמו ה-HMM הסופי, במידע שהיה זמין לפני תחילת ה-Test. אף אחד מהם אינו משתמש ב-Test targets לצורך התאמה.

4.2 Baselines ML Supervised

כדי לבדוק אם הקושי החינווי נובע מבחירת HMM דווקא, נוספו שלושה classifiers המקבלים בדיוק את אותו Vector Feature ואותו split כרונולוגי:

- Logistic Regression עם $C = 1$ ו-scaling על Train בלבד.

- Random Forest Classifier עם 500 עצים, depth מרבי 6 ו-size leaf minimum של 10.

- HistGradientBoostingClassifier עם 200 learning iterations, rate 0.05 ו-15 leaves לכל היותר.

ה-hyperparameters נקבעו מראש, ללא search על Validation או Test, ושלושת המודלים הותאמו על Train בלבד. לכן הם משמשים **Baselines משלימים** ולא תחרות head-to-head מושלמת על כמות זהה של pre-Test observations: ה-HMM, לאחר בחירת K ו-seed על Validation, עובר refit על Train+Validation. מטרת ההשוואה היא לבדוק

האם מודלים ליניאריים ולא-ליניאריים פשוטים מחלצים signal חזיוני ברור מאותם Features, ולא להכריז על classifier אופטימלי.

4.3 מדדים

המדד המרכזי לחיזוי כיוון הוא Directional Prediction Accuracy (DPA):

$$DPA = \frac{1}{N} \sum_{t=1}^N \mathbb{I}[\text{sign}(\hat{r}_{t+1}) = \text{sign}(r_{t+1})]. \quad (10)$$

למודלים שמחזירים תחזית מספרית לתשואה נמדדו גם MAE ו-RMSE על **return log next-day**. בנוסף נשמר MAPE על מחיר הסגירה המשתמע מהתחזית, בעיקר כדי לשמור התאמה למדדים שנקבעו בתכנון הפרויקט [9]. MAPE אינו המדד המרכזי כאן: מחיר מחר בדרך כלל קרוב למחיר היום ולכן MAPE על מחיר יכול להיראות נמוך גם עבור Baseline פשוט, בעוד תשואה יומית יכולה להיות קרובה לאפס ולהפוך MAPE על תשואה לבלתי יציב.

עבור מודלי classification נמדדו גם Score, Brier, Loss Log ROC-AUC, Accuracy, Balanced. המדדים האחרונים חשובים משום ש-Accuracy רגיל עלול להיראות גבוה כאשר שיעור הימים החיוביים גבוה יחסית. עבור classifiers, ה-DPA שקול ל-accuracy של מחלקת הכיוון; עבור המודלים שמחזירים $\hat{r}_{t+1}$, הכיוון נגזר מסימן התחזית.

ל-HMM נשמרו בנוסף, log-likelihood, AIC/BIC, convergence, Transition occupancy, dwell Matrix, time, confidence posterior וזמן התאמה. מדדים אלה אינם מדדי forecasting; הם מתארים התאמה פנימית, מורכבות ומבנה של המודל. זמן הריצה נשמר לצורך reproducibility ולא שימש לבחירת מודל.

4.4 ניסוי Robustness

מעבר ל-split held-out נוספו שלושה סוגי בדיקות:

1. **Seed stability:** התאמת כל K בחמישה seeds והשוואת חלוקת הימים באמצעות Adjusted Rand Index (ARI).
 2. **Walk-forward SPY:** שלושה windows, expanding כאשר בכל fold נבנים Validation Train, Test ו-Validation חדשים באופן כרונולוגי.
 3. **validation: cross-asset / External:** השוואת states של SPY ל-VIX, שלא שימש באימון, ובחינת התנהגות נכסים אחרים כתלות ב-SPY state.
- בדיקות אלה אינן נועדו לשפר את Test בדיעבד, אלא לבדוק אם המסקנות התיאוריות נשארות סבירות גם מעבר לריצה יחידה.

5 תוצאות: מבנה המשטרים

5.1 בחירת מודל ויציבות

בריצה המורחבת נבחר $K = 4$ עבור שמונה מתוך תשעת הנכסים; עבור TLT נבחר $K = 3$. הבחירה נעשתה לפי log-likelihood Validation בלבד. העובדה ש- $K = 4$ נבחר ברוב הנכסים אינה כשלעצמה הוכחה שזהו מספר states "אמיתי"; לכן נבדקה גם יציבות בין seeds.


ב-SPY, השוואת המועמדים מראה מדוע $K = 4$ נבחר. המבלה משתמשת ב-seed בעל log-likelihood Validation הטוב ביותר לכל K , לפני ה-refit הסופי על Train+Validation.

(%) occupancy Min	(Train) BIC	obs. / LL Val.	Seed	K
30.19	14935.6	5.206-	789	2
4.16	13415.1	4.759-	123	3
4.06	12148.8	4.626-	456	4

טבלה 1: השוואת $K = 2, 3, 4$ עבור SPY בשלב בחירת המודל. log-likelihood Validation גבוה יותר (פחות שלילי) עדיף; BIC נמוך יותר עדיף.

גם likelihood Validation וגם BIC מעדיפים כאן את $K = 4$; AIC מציג אותו סדר העדפה. עם זאת, ה-occupancy המינימלי יורד לכ-4%. לכן לא הסתפקנו בקריטריון התאמה בלבד ובדקנו גם יציבות בין seeds ומשמעות סטטיסטית של ה-states. לאחר בחירת $K = 4$ ו-456 seed, המודל הסופי הותאם מחדש על Train+Validation; ה-SPY refit התכנס ב-125 iterations וזמן ההתאמה היה כ-0.79 שניות בסביבת הריצה המאומתת.

עבור SPY, ה-ARI הממוצע בין חמשת ה-seeds ב- $K = 4$ היה 0.995, עם מינימום של 0.992. גם QQQ ו-NVDA היו יציבים מאוד, עם ARI של כ-0.960 ו-0.984 בהתאמה. לעומת זאת, BTC-USD ו-GLD היו פחות יציבים ב- $K = 4$, עם ARI של כ-0.553 ו-0.681. לכן המסקנה אינה שכל נכס "בנוי מארבעה משטרים", אלא שהמודל העשיר יציב במיוחד בחלק מהנכסים ופחות באחרים.



איור 1: יציבות חלוקת ה-states בין seeds לפי ARI. ערכים קרובים ל-1 מצביעים על חלוקה דומה מאוד גם לאחר שינוי initialization.

5.2 פירוש states ב-SPY


SPY משמש מקרה המבחן המרכזי. הטבלה הבאה מסכמת את ארבעת ה-states על פני ההיסטוריה. השמות הם פרשנות post-hoc בלבד; הם לא הוזנו למודל.

משך ימים	DD Mean (%)	Range (%)	Vol. (%)	חשואה יומית (%)	שכיחות (%)	פרשנות	State
25.0	1.72-	0.841	0.692	0.053	34.31	moderate / Normal	0
32.4	0.42-	0.586	0.415	0.092	25.00	low-vol / Calm	1
8.0	15.28-	3.614	3.409	0.265-	4.46	crisis-like / stress Rare	2
35.2	8.11-	1.497	1.239	0.039	36.23	high-vol Persistent	3

טבלה 2: מאפייני states של SPY. Vol. היא סטיית תקן יומית ו-DD Mean הוא drawdown ממוצע.

State 2 בולט במיוחד: הוא נדיר, בעל תשואה יומית ממוצעת שלילית, volatility של כ-3.41%, range daily של כ-3.61%, drawdown mean של כ-15.3% ו-drawdown worst של כ-33.7%. לעומתו State 1 הוא state שקט עם volatility של כ-0.42% קטן יחסית. זו הפרדה שמצדיקה לדבר על משטרים סטטיסטיים שונים, גם אם אין להם labels כלכליים חד-משמעיים.

התנהגות ה-volume מפרידה פחות בבירור בין המשטרים. ממוצע שינוי ה-log-volume היה בקירוב 0.21%, 0.00%, 2.11% ו-0.61% ב-States 0, 1, 2, בעוד ממוצע השינוי המוחלט נשאר בטווח צר יחסית של כ-23.9%--26.5%. לכן במקרה של SPY ההבדלים ב-range, volatility, drawdown משמעותיים יותר לפרשנות המשטרים מאשר ה-volume לבדו.




איור 2: מחיר SPY בתקופת Test צבוע לפי ה-state הדומיננטי. הרצפים המתמשכים ממחישים שהמודל אינו מחליף state באופן אקראי בכל יום.

5.3 Posterior uncertainty סביב מעברים

ה-posterior confidence הממוצע ב-SPY הוא כ-96.6%. עם זאת, ה-entropy הממוצע בימי switch state הוא 0.307 לעומת 0.054 בלבד בימים ללא switch. גם בחלון של יום לפני/אחרי מעבר מתקבל entropy ממוצע של כ-0.236. לעומת זאת, המתאם בין entropy לבין return absolute הוא רק 0.027, והמתאם עם volatility rolling הוא כ-0.076.


הממצא מצביע על כך שה-posterior מכיל מידע על מידת הביטחון של המודל, ולא רק label. state. עם זאת, יש כאן נקודת זהירות חשובה: switch hard מוגדר לפי שינוי ב-argmax של אותו posterior, ולכן צפוי במידה מסוימת שימים סמוכים לגבול בין שני states יהיו גם ימים בעלי entropy גבוהה יותר. לכן הקשר בין entropy ל-switch משמש כאן בעיקר **diagnostic פנימי של ambiguity**, ולא validation חיצוני עצמאי של שינוי משטר. העובדה שה-entropy כמעט אינה מתואמת עם return absolute או volatility rolling עדיין מראה שהיא אינה רק proxy פשוט לעוצמת התנודתיות.



איור 3: entropy Posterior לאורך תקופת Test של SPY. קפיצות באנטרופיה מופיעות בעיקר סביב שינויי state.

5.4 External validation מול VIX

ה-VIX לא שימש Feature ולא השתתף באימון. לכן הוא משמש בדיקת post-hoc חיצונית של פרשנות ה-states, ולא בדיקת forecasting. בתקופת החפיפה של 412 ימי 1 State Test של SPY היה קשור ל-VIX ממוצע של 12.96, 0 State ל-15.34 ו-3 State ל-18.55. ב-3 State כ-26.1% מהימים היו מעל, $VIX=20$ לעומת 6.15% ב-0 State ואפס ב-1 State.



איור 4: רמת VIX לפי state של SPY. אינו חלק מווקטור התכונות ולכן משמש אינדיקציה חיצונית לפרשנות המשטרים.

2 State הנדיר לא הופיע בחפיפה זו ולכן אי אפשר להשתמש ב-VIX כדי לאמת אותו בתקופת ה-Test. בנוסף, entropy עצמו כמעט אינו מתואם עם רמת VIX, ולכן אין לזהות בין "אי-ודאות של ה-HMM" לבין "פחד בשוק".

5.5 Cross-asset behavior

כדי לבדוק האם state של SPY משקף מצב שוק רחב יותר, חושבו סטטיסטיקות של נכסים אחרים מותנות ב-SPY state. ב-3 State הקורלציה עם SPY מגיעה לכ-0.978 ב-QQQ, 0.773 ב-HYG, 0.631 ב-BTC-USD, 0.680 ב-JPM ו-0.769 ב-NVDA. באותו TLT נמצא בקורלציה קרובה לאפס ואף מעט שלילית (-0.044).

Asset	0 State Corr.	1 State Corr.	3 State Corr.
QQQ	0.924	0.849	0.978
IWM	0.733	0.240	0.879
TLT	0.213	0.265	-0.044
HYG	0.636	0.515	0.773
BTC-USD	0.207	0.329	0.631
JPM	0.435	0.106	0.680
NVDA	0.575	0.548	0.769

טבלה 3: קורלציה עם SPY כתלות ב-State Hidden של SPY בתקופת ה-Test.

התוצאה תומכת בפרשנות של ה-HMM כ-market-state latent estimator: state אינו רק תיאור של תנודתיות SPY, אלא מתקשר גם לשינוי במבנה התלות בין asset classes. עם זאת, מדובר בניחות תיאורי על מדגם Test מוגבל: בתקופת החפיפה היו 325 ימים ב-0 State, אך רק 41 ימים ב-1 State ו-46 ב-3 State, בעוד 2 State לא הופיע. לכן לא מוצגת כאן טענת מובהקות או סיבתיות לגבי שינויי הקורלציה.


6 תוצאות: חיזוי יום-קדימה

6.1 תמונה כללית

טבלה 4 מציגה את ממוצע ה-DPA הבלתי-משוקלל בין תשעת הנכסים. בניגוד לגרסה מוקדמת של הסיכום, כאן מוצגים גם שלושת ה-Baselines הפשוטים שהוגדרו מראש — Average Moving persistence, ו-Markov Discrete Chain — לצד מודלי ה-ML Supervised וה-HMM. התוצאה החשובה ביותר היא שאין מודל אחד שמציג יתרון חיזויי עקבי.

(%) DPA Mean	Model
54.54	mean train - Naive
54.14	Regression Logistic
53.90	Chain Markov Discrete
53.27	Classifier Forest Random
53.06	posterior soft - HMM Gaussian
52.49	HistGradientBoostingClassifier
52.06	state hard - HMM Gaussian
50.45	persistence - Naive
50.27	5 Average Moving

טבלה 4: ממוצע DPA בין תשעת הנכסים לכל המודלים שנבדקו. הממוצע אינו שקול למבחן מובהקות ואינו מוכיח עליונות כללית של אף מודל.



איור 5: השוואת DPA לפי נכס עבור Naive, train-mean, שלושת מודלי ה-ML Supervised ו-HMM hard/soft. שלושת ה-Baselines הפשוטים הנוספים מוצגים בטבלה 4 אך אינם נכללים באיור כדי לשמור עליו קריא.

6.2 תוצאות לפי נכס

יש כמה מקרים מקומיים מעניינים. ב-QQQ, Forest Random השיג 59.22%, HMM soft השיג 58.98%, וה-Naive train-mean השיג 58.74%. ב-BTC-USD, Forest Random השיג 52.94% וה-HMM soft השיג 52.05%, לעומת 51.34% ל-Naive. לעומת זאת, ב-JPM ה-Naive הגיע ל-57.52% בעוד HMM soft הגיע ל-51.70%. ב-TLT, HistGradientBoosting היה הטוב ביותר מבין המודלים שנבדקו עם 53.40%, בעוד HMM soft הגיע ל-47.09%; וה-Chain Markov Discrete הגיע שם ל-51.94%.

הפיזור הזה חשוב יותר מהדירוג הממוצע: HMM אינו נכשל בכל נכס, אך גם אינו מנצח בצורה יציבה. אותו דבר נכון למודלי ה-ML Supervised ול-Baselines הקלאסיים. לכן אין evidence לכך שה-Vector Feature הנוכחי מכיל signal חזק ועקבי לחיזוי direction. next-day.

6.3 שגיאת magnitude: דוגמת SPY

DPA בודק רק את סימן התחזית, ולכן עבור המודלים שמחזירים תחזית מספרית להשוואה נבדקו גם MAE ו-RMSE על return log next-day ו-MAPE על מחיר הסגירה המשתמע. הטבלה הבאה מציגה את SPY, מקרה הייחוס המרכזי:

Model	(%) DPA	return MAE	return RMSE	price MAPE (%)
mean train - Naive	58.50	0.00577	0.00766	0.577
persistence - Naive	53.16	0.00816	0.01043	0.816
5 Average Moving	53.16	0.00651	0.00846	0.651
Chain Markov Discrete	58.50	0.00579	0.00769	0.579
state hard - HMM Gaussian	58.50	0.00577	0.00767	0.577
posterior soft - HMM Gaussian	58.50	0.00577	0.00767	0.577

טבלה 5: מדדי חיוזי מספריים על SPY. ההבדלים בין train-mean Naive ל-HMM קטנים מאוד; MAPE על מחיר מוצג כמדד משלים בלבד.

גם במדדי magnitude אין כאן יתרון מעשי גדול: HMM hard/soft כמעט זהים ל-train-mean Naive על SPY. הדבר מחזק את המסקנה שהערך המרכזי של ה-HMM בניסוי הנוכחי אינו תחזית נקודתית מדויקת יותר.

6.4 למה DPA לבדו עלול להטעות

ב-SPY, למשל, train-mean Naive ו-HMM מגיעים ל-DPA של כ-58.50%. עם זאת, Regression Logistic מגיע ל-DPA של 58.01% אך Accuracy Balanced של כ-49.6% ו-ROC-AUC של כ-47.3%. Forest Random משיג ROC-AUC של כ-50.4%. כלומר חלק ניכר מה-Accuracy נובע מחוסר איזון בין ימי Up ו-Down, ולא מיכולת חזקה לדרג ימים לפי הסתברות לעלייה.

זו הסיבה שבדוח לא מתייחסים ל-DPA מעל 50% בהוכחה אוטומטית ל-edge predictive. מודל שמנבא את המחלקה הנפוצה יכול לקבל Accuracy סביר גם בלי להבין את דינמיקת היום הבא.


6.5 state Hard לעונות posterior Soft

בממוצע, HMM soft משיג 53.06% לעומת 52.06% ל-hard-state. הפער קטן, אך הוא עקבי עם האינטואיציה שלפיה שימוש בכל וקטור ה-posterior שומר מידע שנזרק ב-argmax. לדוגמה, ב-HMM hard QQQ הגיע ל-56.31% בעוד HMM soft הגיע ל-58.98%; ב-BTC-USD הפער גדול יותר, 48.13% לעומת 52.05%. מנגד קיימים גם נכסים שבהם soft אינו משפר.

לכן המסקנה אינה ש-posterior soft "פותר" את forecasting, אלא שהוא דרך הגיונית יותר לנצל posterior uncertainty מאשר assignment hard כאשר משתמשים ב-HMM לתחזית.

6.6 robustness Walk-forward על SPY

שלושת ה-folds walk-forward מציגים תמונה מעורבת. HMM soft השיג בהתאמה 50.36%, 51.82% ו-60.22%; train-mean Naive השיג 48.54%, 52.92% ו-59.85%. הממוצע הוא 54.14% ל-HMM soft לעומת 53.77% ל-Naive, אך HMM אינו מנצח בכל fold והפער הכולל קטן.



איור 6: DPA בשלושה folds walk-forward expanding על SPY ה-HMM אינו מפגין יתרון עקבי בין התקופות.

בדיקת ה-walk-forward מחזקת את הצורך בניסוח זהיר: ייתכן שמידע על regime מסייע בתקופות מסוימות, אך לא נמצא advantage predictive יציב שניתן להכליל לכל תקופה.

7 דיון

הממצא המרכזי של העבודה אינו HMM "מנבא את השוק", אלא כמעט ההפך: גם HMM וגם classifiers פשוטים וגם Baselines מתקשים להפיק signal עקבי לחיזוי היום הבא מתוך ארבעת ה-Features שנבדקו. התוצאה השלילית הזו אינה כישלון של הניסוי; היא מאפשרת להפריד בין שתי יכולות שונות של מודל — forecasting ו-representation.

7.1 למה חיזוי יום-קדימה נשאר קשה?

חיזוי סימן התשואה ליום הבא הוא בעיה בעלת יחס signal-to-noise נמוך. Features כמו volatility rolling ו-daily range מתארים היטב את סביבת הסיכון, אך אינם בהכרח מנבאים את סימן התשואה של יום בודד. העובדה שגם Forest Random Regression, Logistic Regression, ו-HistGradientBoosting אינם מייצרים יתרון עקבי תומכת בפרשנות שהקושי אינו ייחודי ל-HMM.

בנוסף, DPA רגיש ל-class balance. בתקופות שבהן שיעור ימי העלייה גבוה, baseline פשוט שמנבא את הכיוון הדומיננטי יכול להשיג DPA מעל 50%. לכן Accuracy Balanced ו-ROC-AUC חשובים לבדיקת signal חיזוי אמיתי. ברוב הנכסים מדדים אלה נשארו קרובים ל-50%, ולכן לא נכון להסיק מה-DPA בלבד שיש יכולת forecasting חזקה.

7.2 מה ה-HMM כן מוסיף?

בניגוד ל-classifier, HMM בונה ייצוג מפורש של מצב לטנטי ושל דינמיקת המעבר בין states. ב-SPY ההפרדה בין states ניכרת במספר ממדים בוזמנית: return, volatility, drawdown range, ו-time dwell. confidence גבוה ברוב הימים, והאנטרופיה עולה כאשר המודל נמצא באזור ambiguity בין states. חשוב לא להפריז בפרשנות של הקשר הזה: מאחר ש-switch נגזר מאותו entropy posterior, גבוהה סביב switch היא בחלקה תוצאה צפויה של הגדרת הגבול. לכן זהו diagnostic פנימי של confidence, לא validation עצמאי.

הראיות החיצוניות יותר מגיעות ממקומות אחרים: VIX שלא שימש באימון מפריד בין חלק מה-states, והקורלציה של SPY עם נכסים אחרים משתנה לפי state. גם כאן מדובר ב-evidence descriptive post-hoc ולא בהוכחה סיבתית, אך הוא מראה שה-state קשור למאפייני שוק שאינם חלק ישיר מה-Vector Feature של SPY.

לכן ה-HMM מספק **context market conditional**. במקום לשאול רק "האם מחר יהיה Up?" ניתן לשאול "באיזה סוג סביבה סטטיסטית אנחנו נמצאים, כמה המודל בטוח בכך, וכיצד נכסים אחרים נוטים להתנהג בסביבה זו?". זו יכולת שאינה נמדדת ישירות ב-DPA.

7.3 Expressiveness חול robustness

העבודה מראה גם trade-off בין מספר states לבין יציבות. $K = 2$ נוטה להיות יציב מאוד בין seeds אך גם יחסית. $K = 4$ מאפשר להפריד states עשירים יותר, וב-SPY, QQQ ו-NVDA הוא גם יציב מאוד. לעומת זאת ב-BTC-USD וב-GLD הוא רגיש יותר לאתחול. מכאן שאין הצדקה לקבוע מספר states אוניברסלי לכל asset class.

7.4 האם ניתן לקרוא ל-"Bull", "Bear" ו-"Crash"?

לא באופן אוטומטי. מספר state הוא label שרירותי, והמודל אינו לומד מושגים כלכליים בשפה אנושית. לכן בדוח נעשה שימוש בשמות תיאוריים רק כאשר הנתונים תומכים בהם. למשל 2 State של SPY מכונה crisis-like משום שהוא נדיר, בעל return שלילי, volatility גבוהה ו-drawdown עמוק. גם שם זה הוא פרשנות ולא truth. ground

7.5 משך המשטר והנחת Markov

ההשוואה בין $1/(1 - a_{ii})$ לבין time dwell אמפירי לא חשפה פער גדול בממוצע עבור SPY. לכן אין בסיס למעון שהנחת duration הגאומטרית נכשלת בניסוי זה. עם זאת, בדיקת ממוצעים אינה בוחנת tails או multimodality של Model Semi-Markov Hidden durations; יכול להיות הרחבה טובה אם רוצים למדל משך משטר במפורש [4].

בסיכום, התמונה העקבית ביותר היא שה-Gaussian HMM מתאים בפרויקט זה יותר ל-**estimation state latent** מאשר ל-**forecasting point**. זו אינה נסיגה מהמטרה המקורית אלא ממצא אמפירי שמגדיר בצורה מדויקת יותר היכן המודל מספק ערך.

8 הרחבה עתידית: Learning Reinforcement Regime-aware

הרחבה טבעית של הפרויקט היא מעבר מבעיה של חיזוי לבעיה של קבלת החלטות סדרתית. ב-Learning Supervised אנו מגסים ללמוד פונקציה מה-Features אל יעד ידוע מראש, למשל $P(y_{t+1} = 1 | x_t)$. ב-Reinforcement Learning הסוכן אינו נדרש רק לומר מה צפוי לקרות; הוא בוחר פעולה המשפיעה על הרווח המצטבר לאורך זמן.

8.1 ניסוח כ-Markov Decision Process

ניתן להגדיר את בעיית המסחר כ-MDP שבו בכל יום קיימים action observation, ו-reward. לדוגמה:

• **Observation:** ארבעת ה-Features הנוכחיים, probabilities posterior של ה-HMM, posterior, entropy והפוזיציה הנוכחית בתיק.

• **Action:** בגרסה פשוטה sell / hold / buy; בגרסה רציפה יותר — משקל $w_t \in [0, 1]$ בנכס.

• **Reward:** תשואת התיק נמו לאחר costs, transaction עם penalty אופציונלי ל-turnover או לסיכון.

ניסוח אפשרי של reward הוא:

$$R_{t+1} = w_t r_{t+1} - c |w_t - w_{t-1}| - \lambda \text{RiskPenalty}_{t+1}, \quad (11)$$

כאשר c מייצג עלות עסקה ו- λ את משקל רתיעת הסיכון. בניגוד לניסוחי החיזוי הנוכחי, כאן costs transaction אינם פרט שולי: policy שמחליפה פוזיציה לעיתים קרובות יכולה להיראות מוצלחת לפני עלויות ולהיכשל לאחריהן.

8.2 למה לשלב HMM בתוך RL?

הרעיון המעניין ביותר אינו להחליף את ה-HMM ב-RL, אלא להשתמש ב-HMM כשכבת estimation. state במקום לתת לסוכן label hard כמו State "3", ניתן להזין את כל הווקטור

$$[\gamma_t(1), \dots, \gamma_t(K), H_t], \quad (12)$$

כך שהסוכן יודע גם מהו regime הסביר וגם כמה ה-HMM בטוח בו. לדוגמה, policy יכולה ללמוד באופן עצמאי שתקופה בעלת posterior חד דורשת פעולה שונה מתקופה שבה שני states מתחרים ביניהם. אין צורך לקודד מראש כלל כמו "ב-state crisis מוכרים"; ה-RL בודק אם מידע זה אכן מועיל ל-reward.

הניסוי הנקי ביותר יהיה ablation בשלוש רמות:

1. **RL-Features:** הסוכן רואה רק את ארבעת ה-Features המקוריים.
2. **RL-Regime:** אותם Features בתוספת HMM posterior probabilities.
3. **RL-Regime-Uncertainty:** תוספת entropy posterior ומידע על הפויציה הנוכחית.

השוואה כזו הייתה עונה על שאלה ממוקדת: האם מידע לטנטי על regime מוסיף ערך אינקרמנטלי למדיניות מעבר למידע הגולמי שכבר קיים ב-Features? זהו המשך ישיר יותר של העבודה מאשר להריץ אלגוריתם RL שאינו משתמש בתוצאות ה-HMM.

8.3 אלגוריתמים אפשריים

לפעולות דיסקרטיות ניתן להתחיל במודל actor-critic פשוט. לפעולת allocation רציפה, שתי אפשרויות טבעיות הן PPO [15] ו-SAC Soft Actor-Critic [6]. PPO נפוץ בגלל עדכוני יציבים יחסית באמצעות objective; clipped entropy. SAC מתאים במיוחד ל-control continuous ומעודד exploration באמצעות entropy.

קיימות מסגרות ייעודיות כמו FinRL, שנבנו כדי לפשט את הגדרת סביבת המסחר, pipeline data ו-market frictions [11]. עם זאת, שימוש בספרייה אינו פותר את שאלות המתודולוגיה: עדיין צריך להגדיר, actions, reward, evaluation. walk-forward ו-seeds multiple train/validation/test, costs, transaction

8.4 מה מראה הספרות?

התמונה בספרות אינה חד-משמעית. al. et Yang אימנו ensemble של A2C PPO ו-DDPG על 30 מניות Dow Jones ודיווחו על ratio Sharpe גבוה יותר מהמדד ומתיק minimum-variance בניסוי שלהם [17]. Zohren Zhang, Roberts and בחנו RL Deep על 50 חוזים עתידיים ממספר classes asset ודיווחו על ביצועים חיוביים גם בנוכחות costs transaction משמעותיים [18].

מצד שני, תוצאות חיוביות אינן מובטחות כאשר מרחיבים את הבדיקה. Müller and Kruthof בחנו SAC על שבעה datasets של מניות עם יותר מ-300 out-of-sample מצטברות. הם מצאו שהמודל לא ניצח באופן שיטתי baseline של $1/N$ גם ללא, turnover גבוה גרם לביצועים נמו שליליים כבר תחת עלויות עסקה מתונות של 0.1% [10]. המסקנה מכאן אינה ש-RL "לא עובד", אלא שהערכתו רגישה מאוד לפרוטוקול, לעלויות ולבחירת benchmark.

8.5 כיצד היינו מבצעים את הניסוי בצורה הוגנת?

כדי שהרჩבה כזו תהיה משכנעת, היינו שומרים על אותם עקרונות שהנחו את הפרויקט הנוכחי:

- חלוקה כרונולוגית ו-walk-forward, ללא shuffle.
- התאמת HMM ו-scaler על המידע הזמין באותו fold בלבד.
- seeds multiple לכל, policy משום ש-RL Deep רגיש לאתחול.

- turnover costs transaction מפורשים ב־reward ובהערכה.
- Baselines כגון policy Average, Moving Buy-and-Hold, HMM, ו־policy עם HMM.
- מדדים כגון Sharpe, return, cumulative drawdown maximum ו־turnover, לצד בדיקה אם התוצאות שורדות עלויות עסקה.

לא בוצע ניסוי RL בדוח הנוכחי, ולכן אין כאן טענה שהרחבת RL Regime-aware תשפר ביצועים. היא מוצגת בכיוון מחקר שמנצל באופן ישיר את הממצא המרכזי של העבודה: ה־HMM נראה שימושי יותר כ־estimator state מאשר כ־RL predictor. one-step הוא מסגרת טבעית לבדוק האם estimate state כזה מועיל כאשר הבעיה מוגדרת בקבלת החלטות לאורך זמן ולא בחיזוי סימן של יום בודד.

9 מגבלות

למרות ההרחבות שבוצעו, קיימות מספר מגבלות שחשוב להציג במפורש.

- **Features מוגבלים:** ארבעת ה־Features פשוטים ומכוונים למצב השוק, אך ייתכן שהם אינם מכילים signal מספיק לחיזוי direction. next-day הוספת variables options-implied data, macro order-flow יכולה לשנות את התמונה, אך גם להגדיל סיכון ל־overfitting ול־snooping. data.
- **תקופת Test אחת לכל נכס:** נוסף walk-forward על SPY בלבד. לכן robustness בזמן נבדקה לעומק עבור נכס הייחוס, אך לא עבור כל תשעת הנכסים.
- **בחירת K :** לפי selection model likelihood Validation העדיף ברוב הנכסים $K = 4$. למרות בדיקת seed stability, עדיין ייתכן שמספר states מתאים משתנה בין תקופות או assets.
- **labels: Semantic** שמות כמו calm או crisis-like הם פרשנות post-hoc ולא truth. ground ה־HMM אינו "יודע" מהו משבר כלכלי.
- **validation VIX חלקי:** 2 State הנדיר של SPY לא הופיע בחפיפה עם תקופת ה־Test ולכן לא קיבל external validation מול VIX באותו חלון.
- **Supervised baselines אינם tuning תחרותי:** Random Forest, Logistic Regression, HistGradientBoosting נבחרו כ־Baselines שקופים עם hyperparameters קבועים. המטרה לא הייתה להוכיח מהו classifier הטוב ביותר האפשרי.
- **היקף אימון לא זהה בכל ההשוואות:** לאחר בחירת K ו־seed, ה־HMM הסופי וה־Baselines הפשוטים משתמשים בכל היסטוריית Train+Validation הזמינה לפני Test. מודלי ה־Supervised הקבועים אוּמְנוּ על Train בלבד ו־Validation נשאר ללא שימוש. לכן השוואת ה־DPA ביניהם היא אינדיקציה משלימה ולא ניסוי שבו לכל המודלים הוקצתה בדיוק אותה כמות נתוני אימון.
- **אין backtest למסחר:** DPA אינו שקול לרווחיות. לא נכללו עמלות, taxes slippage או sizing position ולכן אין להסיק מהתוצאות המלצה למסחר.

10 מסקנות

העבודה התחילה משאלה חיונית: האם HMM Gaussian יכול לזהות States Hidden ולנצל אותם כדי לשפר next-day forecasting. direction day לאחר סדרת ניסויים רחבה יותר התקבלה תשובה מפורצלת.

מבחינת forecasting, אין יתרון עקבי. ממוצע ה־DPA בין תשעת הנכסים היה 54.54% ל־Naive, train-mean, 53.06% Forest, Random, 53.27% Chain, Markov Discrete, 53.90% Regression, Logistic, 54.14% HMM, soft, 52.49% HMM, HistGradientBoosting, 52.06% HMM, hard, 50.45% persistence Naive, 50.27% Average Moving, 5. גם walk-forward על SPY מציג פערים קטנים ולא עקביים, ובמדדי MAE/RMSE על SPY ה־HMM כמעט זהה ל־Naive, train-mean. לאור מגבלת היקף האימון הלא־זהה בין HMM

ל-baselines, Supervised אין לפרש את הדירוג הממוצע כתחרות מובהקת ביניהם. בכל מקרה, התוצאות אינן מספקות בסיס למעון שה-HMM "מנבא את השוק" או מציג יתרון יציב על Baselines פשוטים.

מבחינת structure, latent התוצאה חזקה יותר. ב-SPY מתקבלים ארבעה states בעלי מאפייני volatility, return, drawdown range, ומשך שונים. State נדיר אחד מציג מאפייני stress ברורים. חלוקת $K = 4$ יציבה מאוד בין entropy posterior seeds; עולה סביב switches state אך מפורש כ-diagnostic פנימי של VIX ambiguity; חיצוני מפריד בין חלק מה-states; והקורלציה של SPY עם נכסי risk אחרים משתנה כתלות במשטר.

לכן המסקנה הסופית היא שה-Gaussian HMM בפרויקט זה מתאים יותר ל-market conditional modeling structure מאשר ל-forecasting point. הערך שלו אינו בכך שהוא יודע בוודאות מה יקרה מחר, אלא בכך שהוא נותן הקשר הסתברותי: באיזה סוג regime השוק נמצא, כמה state זה מתמשך, כמה המודל בטוח בזיהוי, וכיצד מבנה הסיכון והקשרים בין נכסים משתנים יחד איתו.

הרחבה טבעית היא להשתמש ב-posterior של ה-HMM כ-representation state בתוך Regime-aware Learning, Reinforcement ולבדוק האם מידע זה משפר policy לאורך זמן תחת transaction costs ו-walk-forward evaluation. זוהי שאלה מחקרית שונה מהחזוי שנבדק כאן, והיא דורשת ניסוי נפרד ולא inference מתוך התוצאות הנוכחיות.

א' שחזור והרצה

הדוח והמחברת קוראים תוצאות machine-readable מה-artifacts המאומתים, ולכן ניתן לעיין בהם בלי לאמן מחדש את כל המודלים. הריצות המרכזיות הן:

• `experiments_extended/extended_20260811_121957/`

• `experiments_supervised/supervised_20260811_133344/`

סביבת הריצה המאומתת הייתה Python 3.11.15. בריצת ה-HMM נעשה שימוש ב-hmmlearn 0.3.3, NumPy 2.4.6, pandas 3.0.3 ו-scikit-learn 1.9.0.

להרצה מחדש:

```
python -m pip install -r requirements.txt
python run_extended_analysis.py
python analyze_extended_context.py \
  --run-dir experiments_extended/<run_id>
python run_supervised_baselines.py
jupyter nbconvert --to notebook --execute \
  HMM_Market_Regimes_Project.ipynb \
  --output /tmp/HMM_verified.ipynb \
  --ExecutePreprocessor.timeout=600
```

כל ריצה חדשה נכתבת לתיקיה timestamped חדשה ואינה אמורה לדרוס את התוצרים שעליהם מבוסס הדוח. הדבר חשוב במיוחד משום שמקור הנתונים חיצוני ונתוני Finance Yahoo יכולים להתעדכן לאורך זמן.

מקורות

- [1] Akaike, Hirotugu identification. model statistical the at look new A *Control Automatic on Transactions IEEE* 1974, 723--716:(6)19
- [2] Aroussi, Ran documentation, and software Python api. finance's yahoo! from data market Download yfinance: 2024
- [3] Weiss, Norman and Soules, George Petrie, Ted Baum, E. Leonard the in occurring technique maximization A *Statistics Mathematical of Annals The* chains. markov of functions probabilistic of analysis statistical -164:(1)41, 1970, 171-
- [4] Bulla, Ingo and Bulla Jan *Computational models. semi-markov hidden and series time financial of facts Stylized Bulla* 2006, 2209--2192:(4)51, *Analysis Data & Statistics*
- [5] Valentino, Mario and Schiavone, Lucia Ruggiero, Ludovica Catello, Luigi stock for models markov Hidden *arXiv:2310.03775 preprint arXiv* prediction. market 2023
- [6] Levine, Sergey and Abbeel, Pieter Zhou, Aurick Haarnoja, Tuomas maximum Off-policy actor-critic: Soft *Conference International 35th the of Proceedings In* actor. stochastic a with learning reinforcement deep entropy 2018, 1870--1861 pages, *Learning Machine on*
- [7] Hamilton, D. James business the and series time nonstationary of analysis economic the to approach new A *Econometrica* cycle. 1989, 384--357:(2)57
- [8] hmmlearn: developers. hmmlearn 2024 documentation, Software python. in models markov Hidden
- [9] Koehler, B. Anne and Hyndman J. Rob *Journal International* accuracy. forecast of measures at look Another 2006, 688--679:(4)22, *Forecasting of*
- [10] Müller, Sebastian and Kruthof Garvin *Letters Research Finance* 1/n? beat learning reinforcement deep Can 2025, 75:106866
- [11] Wang, Dan Christina and Gao, Jiechao Yang, Hongyang Liu, Xiao-Yang learning reinforcement Deep Finrl: *arXiv:2111.09395 preprint arXiv* finance. quantitative in trading automate to framework 2021
- [12] Murphy, P. Kevin *Perspective Probabilistic A Learning: Machine* 2012 MA, Cambridge, Press, MIT
- [13] Schmidt, M. Niels and Beest, van M. Floris Langrock, Roland Pohle, Jennifer states of number the Selecting *Agricultural, of Journal* movement. animal using illustrated solutions Pragmatic models: markov hidden in 2017, 293--22:270, *Statistics Environmental and Biological*
- [14] Rabiner, R. Lawrence recognition. speech in applications selected and models markov hidden on tutorial A *IEEE the of Proceedings* 1989, 286--257:(2)77
- [15] Klimov, Oleg and Radford, Alec Dhariwal, Prafulla Wolski, Filip Schulman, John optimization policy Proximal *arXiv:1707.06347 preprint arXiv* algorithms. 2017
- [16] Schwarz, Gideon *Statistics of Annals The* model. a of dimension the Estimating 1978, 464--461:(2)6
- [17] Walid, Anwar and Zhong, Shan Liu, Xiao-Yang Yang, Hongyang automated for learning reinforcement Deep *Finance in AI on Conference International ACM First the of Proceedings In* strategy. ensemble An trading: stock 2020, 8--1 pages, (20' *ICAIF*
- [18] Roberts, Stephen and Zohren, Stefan Zhang, Zihao *preprint arXiv* trading. for learning reinforcement Deep 2019, *arXiv:1911.10107*